

# Aprendizaje e inteligencia computacional para la caracterización de consumo eléctrico en hogares

Autores:

Mathías Esteban

Mateo Mujica

Ignacio Fiori

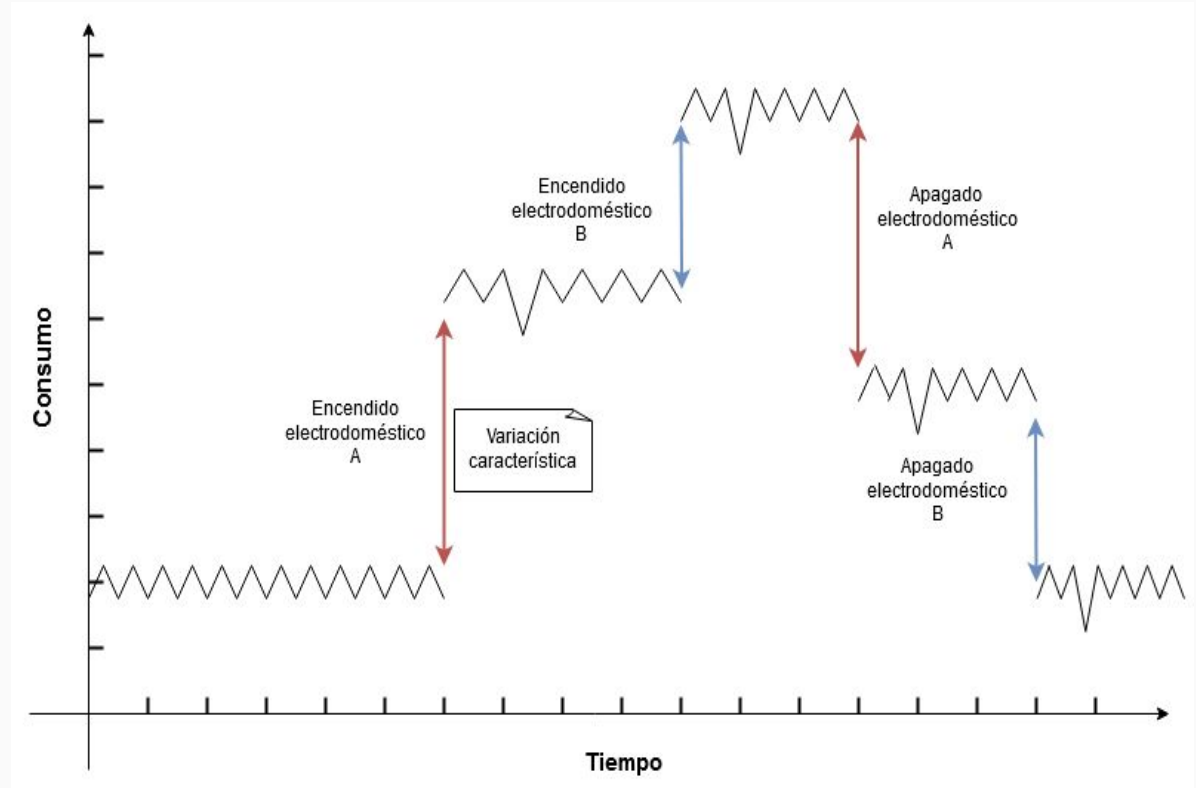
Tutor:

Dr. Sergio Nesmachnow

# Presentación del problema

# Introducción

La caracterización energética doméstica es el proceso mediante el cual se busca identificar qué electrodomésticos se encuentran encendidos en un hogar a partir del registro de consumo total indicado por su contador.




# Antecedentes y trabajos relacionados

- G. Hart, Nonintrusive Appliance Load Monitoring (1992)


Variante binaria



Variante de estados finitos



Variante de consumo continuo



- J. Kelly, Disaggregation of Domestic Smart Meter Energy Data (2016)

# Implementación

# Bibliotecas

Un algoritmo de aprendizaje automático es aquel que tiene la capacidad de aprender determinado comportamiento a partir de los datos que procesa.

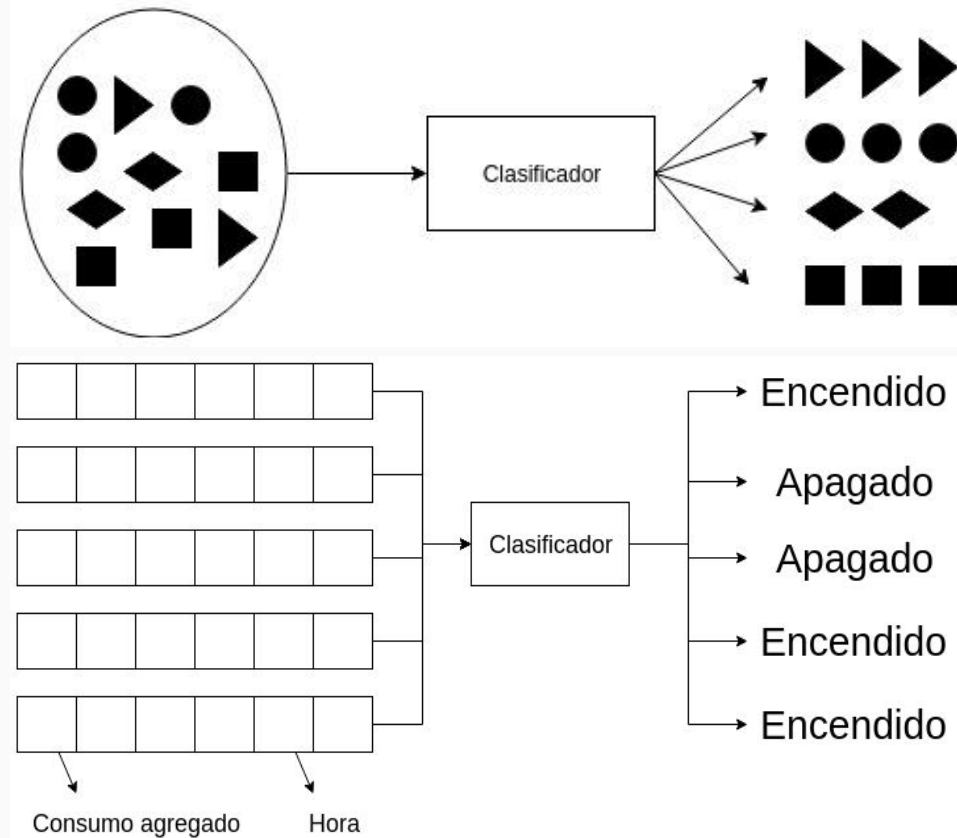


# Problema de clasificación

- Un clasificador es una función que asigna los elementos de un conjunto  $X$  a un conjunto discreto de clases  $Y$ .
- En el problema de caracterización:

**Las entradas** se componen de características que aportan información del electrodoméstico y su entorno.

**Las salidas** corresponden al estado de funcionamiento actual del electrodoméstico.



# Naive Bayes


- Naive Bayes es uno de los algoritmos de clasificación más rápido y sencillo.
- Utiliza el teorema de Bayes para decidir a qué clase pertenece un elemento a clasificar.

$$P(A|B) = \frac{P(B|A) P(A)}{P(B)}$$

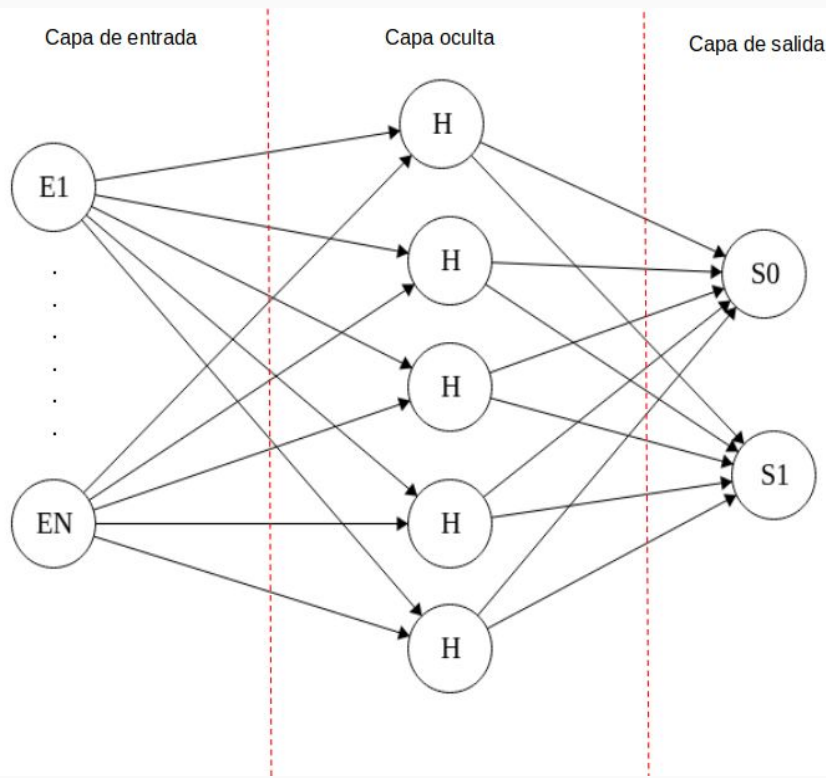


# K Nearest Neighbours

- Clasifica a un elemento según la clase a la que pertenecen la mayor cantidad de los K vecinos más cercanos.
- K suele escogerse impar para evitar problemas de empate.
- En una de sus variantes se puede incorporar la distancia de los vecinos en la decisión.



# Perceptrón multicapa



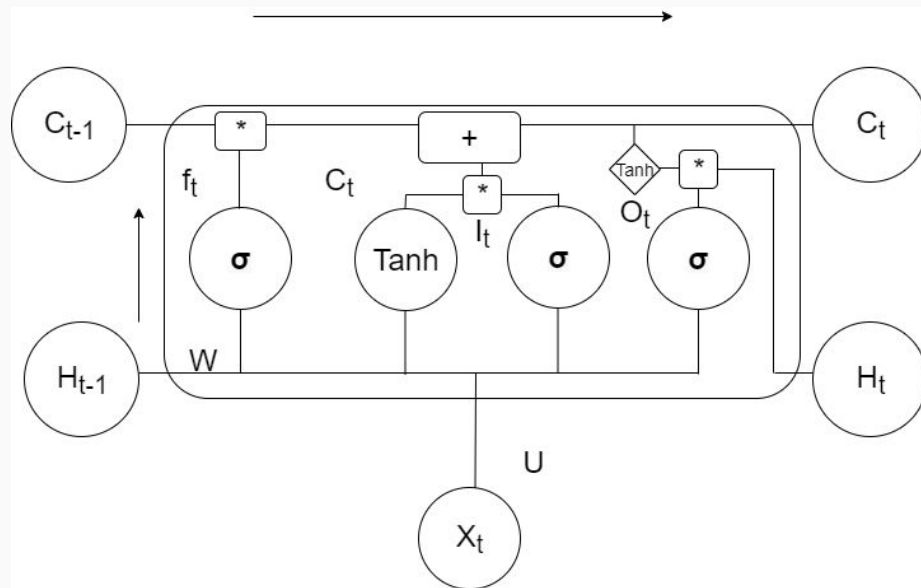
- ❖ Es uno de los modelos más simples de redes neuronales. Consiste en una agrupación de perceptrones donde solo son permitidas las conexiones hacia adelante.
- ❖ Primer arquitectura trabajada:
  - X neuronas de entrada
  - 5 neuronas ocultas
  - 2 neuronas de salida
  - Activación *sigmoid*
  - Descenso por gradiente

# Redes neuronales *Long Short Term Memory*

Las redes neuronales recurrentes incorporan dependencia temporal y son efectivas para el reconocimiento de secuencias. Las redes LSTM son un tipo particular de redes recurrentes cuyas neuronas trabajan como “celdas de memoria”.


## Arquitecturas

- LSTM simple
- LSTM apilado
- LSTM apilado bidireccional
- CNN-LSTM



# Evaluación experimental

# Conjunto de datos UK-Dale



- Información sobre electrodomésticos de hogares en Reino Unido en el período entre los años 2012-2017.
- La frecuencia de muestreo del consumo agregado y de los particulares de cada electrodoméstico es de 1/6Hz.
- Los electrodomésticos estudiados fueron: **lavavajillas, heladera, microondas, jarra eléctrica y lavarropas.**

# Escenarios de prueba

Los datos de UKDALE se procesaron para obtener un conjunto de características que ayuden a la tarea de clasificación. Las diferentes combinaciones de características dieron lugar a diversos escenarios de prueba.

Escenario 1
<ul style="list-style-type: none"><li>- CONSUMO AGREGADO</li><li>- ENCENDIDO ANTERIOR</li><li>- TIEMPO APAGADO</li><li>- FIN DE SEMANA</li></ul>
<ul style="list-style-type: none"><li>- ENCENDIDO   APAGADO</li></ul>

Escenario 2
<ul style="list-style-type: none"><li>- CONSUMO AGREGADO</li><li>- FIN DE SEMANA</li></ul>
<ul style="list-style-type: none"><li>- ENCENDIDO   APAGADO</li></ul>

Escenario 3
<ul style="list-style-type: none"><li>- CONSUMO AGREGADO</li><li>- ENCENDIDO ANTERIOR</li><li>- TIEMPO APAGADO</li><li>- FIN DE SEMANA</li><li>- HORA DEL DIA</li></ul>
<ul style="list-style-type: none"><li>- ENCENDIDO   APAGADO</li></ul>

# Escenarios de prueba

## Escenario 4 (normalizado)

- CONSUMO AGREGADO
- ENCENDIDO ANTERIOR
- TIEMPO APAGADO
- FIN DE SEMANA
- HORA DEL DIA

- ENCENDIDO | APAGADO

## Escenario 5

- FRANJA DE CONSUMO
- ESTADO ANTERIOR
- TIEMPO APAGADO
- TIEMPO ENCENDIDO
- FIN DE SEMANA
- HORA DEL DIA

- ESTADO DE CONSUMO

## Escenario 6

- FRANJA DE CONSUMO

- ESTADO DE CONSUMO

# Escenarios de prueba

## Escenario 7

- ENCENDIDO ANTERIOR
- TIEMPO APAGADO
- TIEMPO ENCENDIDO
- FIN DE SEMANA
- HORA DEL DIA
- VARIACIÓN DE CONSUMO

- ENCENDIDO | APAGADO

## Escenario 8

- VARIACIÓN DE CONSUMO

- ENCENDIDO | APAGADO

## Escenario 9 (entrada)

- ENCENDIDO ANTERIOR
- TIEMPO APAGADO
- TIEMPO ENCENDIDO
- FIN DE SEMANA
- HORA DEL DIA
- VARIACIÓN DE CONSUMO

- ENCENDIDO | APAGADO



# Métricas de desempeño

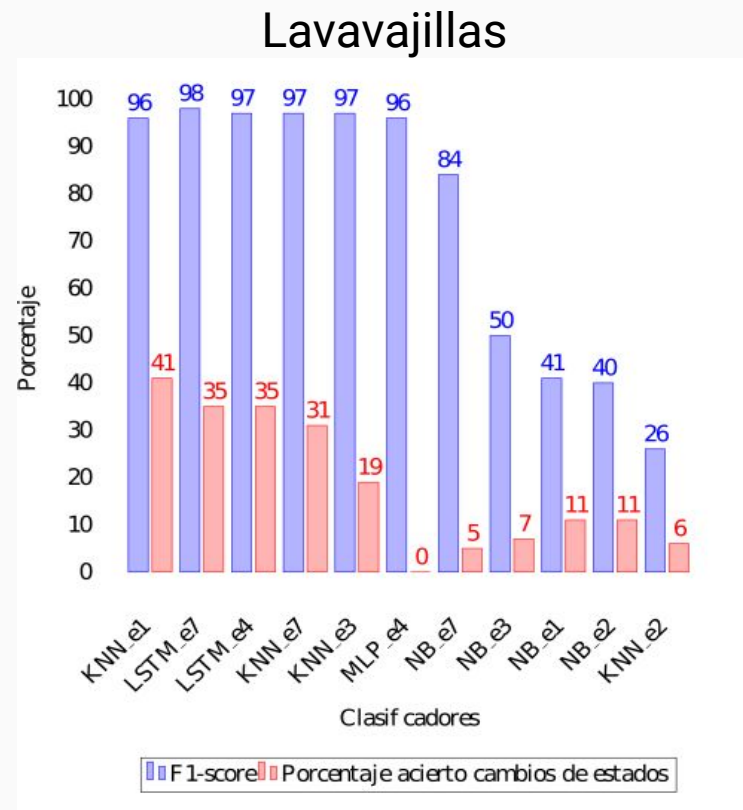
- Las métricas de desempeño son indicadores o medidas que permiten evaluar el rendimiento de un clasificador.
- Las métricas utilizadas en este proyecto fueron **Accuracy, Precision, Recall y F1-Score**. Se definen como:
  - Accuracy** =  $(TP + TN) / (TP + TN + FP + FN)$
  - Precision** =  $TP / (TP + FP)$
  - Recall** =  $TP / (TP + FN)$
  - F1-Score** =  $(2 * Precision * Recall) / (Precision + Recall)$

		Real	
		Positivo	Negativo
Predicción	Positivo	Verdadero Positivo (TP)	Falso Positivo (FP)
	Negativo	Falso Negativo (FN)	Verdadero Negativo (TN)

# Resultados en hogares vistos durante el entrenamiento


En esta instancia se evaluaron los clasificadores con los datos del mismo hogar (electrodoméstico) sobre el cuál se entrenaron.

En la siguiente secuencia de gráficas se ilustran los resultados obtenidos por cada clasificador, comparando las métricas de F1-Score y el porcentaje de acierto de cambios de estado.




# Resultados en hogares vistos durante el entrenamiento

## Jarra eléctrica




## Heladera

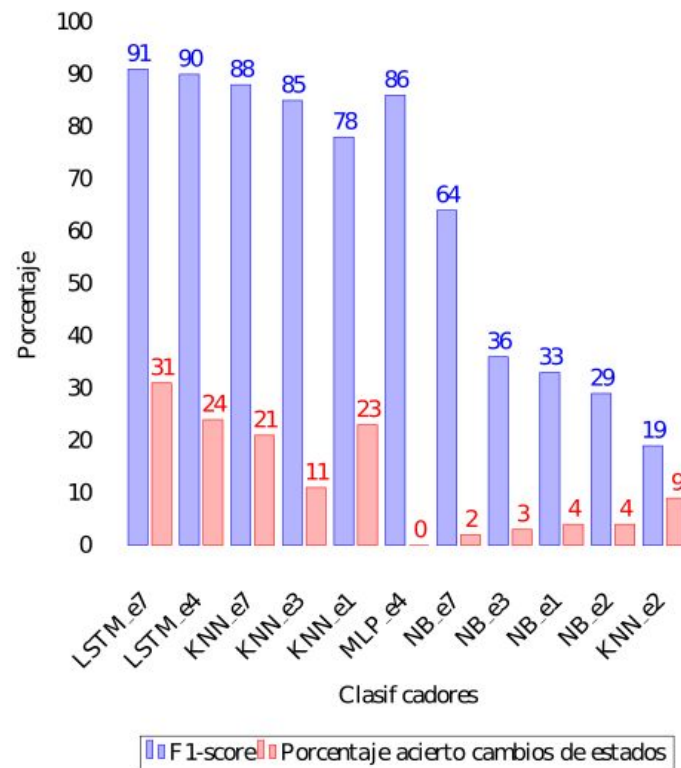


# Resultados en hogares vistos durante el entrenamiento

## Microondas

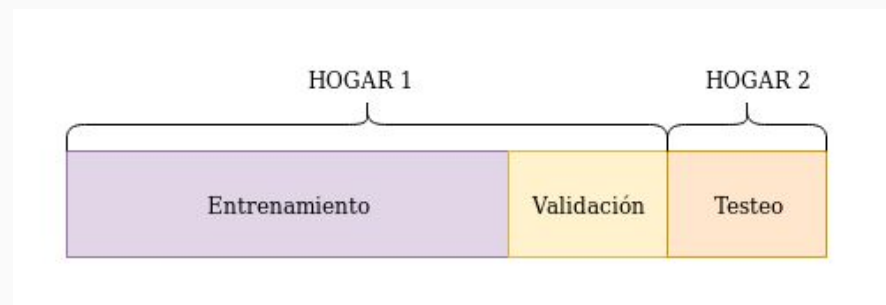


## Lavarropas




# Resultados en hogares no vistos durante el entrenamiento

- En esta instancia se evaluaron los clasificadores con datos de hogares (electrodomésticos) diferentes a los que se utilizaron en las etapas de entrenamiento.
- Se eligieron dos electrodomésticos para realizar estas pruebas: **la heladera y el microondas**.
- Con los clasificadores Naive Bayes y KNN se trabajó sobre los escenarios 3 y 7, mientras que para las redes LSTM los escenarios utilizados fueron el 4 y 7.




# Resultados en hogares no vistos durante el entrenamiento

## Heladera



## Microondas



# Conclusiones y trabajo futuro

# Conclusiones

- Considerar la variación de consumo agregado influyó positivamente en la detección de cambios de estado.
- Utilizar intervalos de tiempo discretizado elevó los valores en métricas de desempeño.
- Buenos resultados en hogares no vistos durante el entrenamiento.







- Datos de hogares uruguayos.
- Extender a mayor cantidad de electrodomésticos.
- Profundizar en el estudio de las redes neuronales.
- Énfasis en la variante de múltiples niveles de consumo.

¿Preguntas?

¡Gracias!

